

实验六：基于 CIFAR-10 子集的代表构建与聚类分析

任务描述：在CIFAR-10 子集数据上完成“表示构建 → 聚类 → 可视化 → 模型选择/敏感性”的完整流程。先用 PCA 获得低维表示，在其上执行 k-means 基线聚类，并与至少一种替代方法（GMM/DBSCAN/谱聚类）进行对比；输出二维可视化与关键曲线（SSE 肘部 / Silhouette-k），给出对参数与数据规模的敏感性结论。

实验要求：

数据与预处理

- 从 CIFAR-10 选 5 个类别，每类 ≤ 600 张（ 32×32 , RGB）。固定随机种子并导出样本清单（csv）。
- 特征至少实现一种：① 原始像素标准化；② 颜色直方图（RGB/HSV）；③ HoG。可叠加使用。

Basic（必做）

- 1: PCA 降维：得到 50 维嵌入（用于聚类）与 2 维坐标（用于可视化）。
- 2: k-means 聚类：在 PCA-50D 上，扫描 $k \in [2, 12]$ ；绘制 SSE 肘部曲线 与 Silhouette-k 曲线，给出最终 k 的选择依据。

实验要求:

3.: 可视化: 在 PCA-2D 上绘制散点 (不同簇用不同标记/颜色), 并展示每簇 3 张最接近簇中心的代表样本。

4: 报告指标: Silhouette、Calinski-Harabasz (CH)、Davies-Bouldin (DB), 以及单次聚类的运行时间与内存 (可由样本量作两到三个点的缩放对比)。

Plus (选一)

- 替代聚类: GMM / DBSCAN / 谱聚类 其一, 与 k-means 在三项指标 (Silhouette/CH/DB) 和耗时上的对比;
- 表示改进: 实现 ≤ 50 万参数的小型自编码器 (CPU 可跑), 提取 16/32 维表示后再聚类, 对比指标与耗时;
- 稳定性: 更换随机种子 5 次, 报告指标 均值 $\pm$ 标准差。